Sémantique et Traduction des Langages Majeure Sciences et Ingénierie du Logiciel

Marc Pantel

2020 - 2021

Organisation

- Cours : 10 séances Marc Pantel
- ► TD : 8 séances Marc Pantel/Neeraj Singh
- ► TP : 9 séances Marc Pantel/Neeraj Singh
- Mini Projets (20%) en binôme : 2 séances de suivi + 1 test Finalisation travaux de TP sur langage fonctionnel miniML Finalisation travaux de TP sur langage impératif miniC
- ▶ Projet (40%) en quadrinôme : 5 séances de suivi + 1 test Extension du langage miniC avec technologies objets
- Examen (40%) : 1h30 avec documents
- Urgent : Constituer les quadrinômes et binômes associés
- Alternative 1 : Pas de confinement
 - Travaux Dirigées en présenciel
 - Travaux Pratiques à décider
- ► Alternative 2 : Confinement
 - Combinaison TD/TP à distance

Plan du cours

- Introduction
 - Rappels : Modélisation, Automates et Graphes, GLS
 - Architecture générale
 - Formes de sémantique
- Interprétation
 - Sémantique opérationnelle
 - Sémantique axiomatique
- Compilation
 - ► Table des Symboles, Arbre abstrait
 - Typage
 - Modèle mémoire, Génération de code
 - Sémantique translationnelle, dénotationnelle
- Vérification de correction

Rappels

- ▶ Modélisation :
 - Structure algébrique des langages
 - Spécification des langages :
 - Expressions régulières,
 - ► Grammaire (règles de production, EBNF, Conway)
- Automates et Théorie des Langages
 - Automates, Automates à piles, Analyseur descendant récursif
 - Générateurs d'analyseurs lexicaux et syntaxiques
- ► Ingénierie Dirigée par les Modèles
 - Métamodèles :
 - Représentation abstraite du langage (MOF),
 - Règles de bonne formation (OCL)
 - Syntaxe concrète texte : Xtext

Principes essentiels

Communication = Echange d'informations

- - ► Reconnaitre une information
 - Exploiter une information

Organisation stratifiée : information structurée

Informatique : Science du traitement de l'information

Computer science : Science de la « machine à calculer »

- Essentiel: Description et manipulation de l'information (langage),
 - ► Traitement d'une information quelconque,
 - ► Traitement d'une manipulation quelconque
 - D'où : Description formelle du langage
 - Génération automatique des outils de manipulation

Références bibliographiques

- ▶ Hopcroft, Ullman, Introduction to automata theory, languages and computation, Addison-Wesley, 1979.
- Stern, Fondements mathématiques de l'informatique, McGraw-Hill, 1990.
- Carton, Langages formels, calculabilité et complexité, Vuibert, 2008.
- Aho, Sethi, Ullman, Compilateurs: Principes, Techniques et Outils, InterEditions, 1989.
- ► Fisher, Leblanc, Crafting a compiler in ADA/in C, Benjamin Cummings, 1991.
- Wilhem, Maurer, Les compilateurs : Théorie, construction, génération, Masson, 1994.
- Appel, Modern Compiler Implementation in Java/ML/C, Cambridge University Press, 1998.
- ▶ Winskel, The formal semantics of programming languages : An introduction, MIT Press, 1993.
- ▶ Lämmel, Software Languages : Syntax, Semantics and Metaprogramming, Springer (under review), 2017.

Exemple: fichier /etc/hosts

► Fichier tel qu'il est affiché :

Informations brutes : caractères

```
0000000
                                                   sp
                              a i r e nl nl
0000020
                       n
               0 . 1 ht h a 1 9
0000040
                                                       0
                                                           sp
           alhostnlnl#spE
0000060
                                                           sp
                                      utrenln1 4 7
0000100
           \texttt{c} \quad \texttt{i} \quad \texttt{sp} \quad \texttt{u} \quad \texttt{n} \quad \texttt{sp} \quad \texttt{a}
                                            1 4 4 ht
0000120
0000140
                                                                       nl
                                                                    r
0000160
```

Analyse lexicale

- ► Informations élémentaires : commentaire, nombre, identificateur, ... (unités lexicales)
- Résultat de l'analyse lexicale :

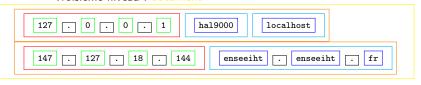
```
# Ceci est un commentaire 127 . 0 . 0 . 1
hal9000 localhost # En voici un autre 147 .

127 . 18 . 144 enseeiht . enseeiht . fr
```

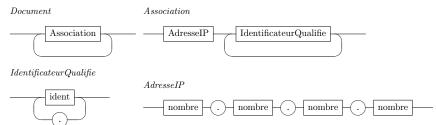
- ▶ Spécification des unités lexicales : Expressions régulières
 - ightharpoonup Commentaire : $\#[^{\n}]^{*} \setminus n$
 - Nombre : $[0 9]^+$
 - ► Identificateur : $[a bA B][a bA B0 9]^*$

Analyse syntaxique

- Informations structurées (unités syntaxiques) :
 - Premier niveau : adresse IP, nom qualifié
 - Deuxième niveau : assocation
 - ► Troisième niveau : document

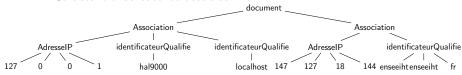


 Spécification des unités syntaxiques : Grammaires (notation de Conway)

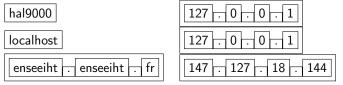


Analyse sémantique

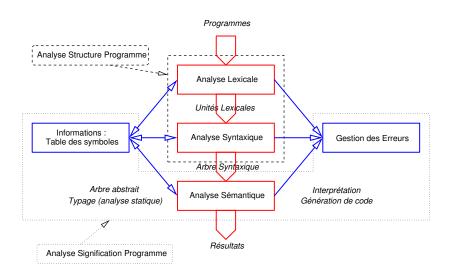
► Structure arborescente associée :



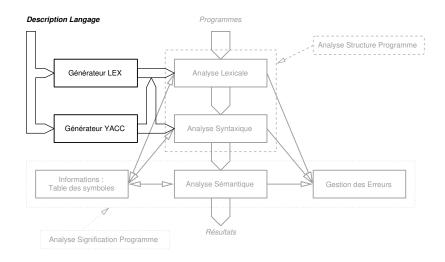
 Exploitation des informations : association nom qualifié/adresse IP (unités sémantiques)



Structure d'un outil

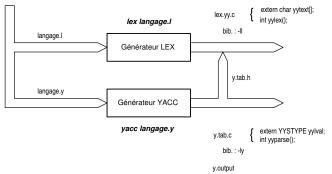


Exemple lex et yacc



Exemple lex et yacc

Description Langage



Définitions

- Caractère/Symbole : Unité élémentaire d'information
- Unité lexicale (lexème, mot) : Séquence de caractères
- Unité syntaxique (arbre syntaxique, syntème, phrase) : Arbre d'unités lexicales
- ► Unité sémantique : diverses (arbre abstrait, table des symboles, type, code généré, résultat évaluation, . . .)

Comment organiser les informations?

- Objectif : Exploitation des informations
- ► Règle : Choisir le bon niveau de précision
- ▶ Unité lexicale : Bloc élémentaire d'information pertinente
- Unité syntaxique : Elément structurant de l'information

Sémantique formelle des langages

- Objectif : Modélisation la sémantique avec des outils mathématique
- Atteindre la qualité de la modélisation de la syntaxe
- Etudier la cohérence et la complétude
- ▶ Prouver la correction des outils
- Générer automatiquement les outils
- Différentes formes :
 - Sémantique opérationnelle : Mécanisme d'exécution des programmes
 - ▶ Sémantique axiomatique : Mécanisme de vérification des programmes
 - Sémantique translationnelle : Traduction vers un autre langage équipé d'une sémantique formelle
 - Sémantique dénotationnelle : Traduction vers un formalisme mathématique
- Validation des sémantique par étude équivalence entre formes

miniML

- Expressions : sans effets de bord, similaire dans tous les langages
- Partie fonctionnelle : sans effets de bord
- Partie Impérative : effets de bord, y compris dans les expressions et la partie fonctionnelle

miniML

Expressions:

```
Expr → Ident

| Const

| Expr Binaire Expr

| Unaire Expr
                    (Expr)
Const \rightarrow entier | booleen
Unaire \rightarrow -
Binaire \rightarrow + | - | * | / | % | & | | | | == | ! = | < | <= | > | >=
```

miniML

► Partie Fonctionnelle :

Partie Impératives :

Interprétation : Principes généraux

- Programme qui exécute un programme (émulateur, machine virtuelle, . . .)
- Langage hôte/support : Langage de programmation de l'interprète
- ► Représenter le programme comme une donnée
- ► Représenter l'exécution comme des données et algorithmes
 - Résultats de l'exécution (dont intermédiaires)
 - ► Ne pas oublier les erreurs d'exécution (résultats possibles)
 - Pour chaque construction exécutable du langage, identifier :
 - 1. Variantes selon résultats intermédiaires
 - 2. Étapes dans chaque variante
 - 3. Contraintes entre les étapes

Représentation des programmes et de l'exécution

Programmes :

- Arbres abstraits : Abstraction de l'arbre de dérivation (arbre syntaxique)
- Structure de graphe (relation définition/utilisation)
 - Approche objet : Métamodèles
 - ▶ Approche fonctionnelle : Structure d'arbres + Tables des symboles

Exécution :

- Valeurs : Exploiter les types de base du langage hôte (booléen, entier, flottant, caractère, chaîne de caractère, . . .)
- Déclarations : Utilisation d'un dictionnaire (table des symboles)
- Mémoire : Adresses et Espace de données associé

Application à miniML

- ► Arbre abstrait : voir vidéo séparée
- ► Valeurs :

$$egin{array}{ccc} extit{Valeur} &
ightarrow & extit{Const} \ ert & ert \end{array}$$

► Algorithme d'exécution : voir vidéo séparée

Sémantique Opérationnelle

- Objectif : Décrire formellement les mécanismes d'exécution des programmes d'un langage
- Principe:
 - Exploiter la syntaxe du langage
 - Décrire l'exécution comme une transformation des programmes
- Notation : Règles de déduction
 - ▶ Soient $J_1, ...J_n$ et J des jugements :

	Notation	Signification
Déduction	$\frac{J_1 \qquad J_n}{J}$	si J_1 etet J_n sont valides alors J est valide
Axiome		J est valide

- ▶ Jugement d'exécution à grand pas : $\gamma \vdash e \Rightarrow v$
 - $ightharpoonup \gamma$: environnement (association *Ident / Valeur*)
 - e : expression (*Expr*)
 - v : valeur (Valeur)
- Partie haute : Étapes intermédiaires (appels récursifs dans interpréte miniML)
- ▶ Partie basse : Construction traitée par la règle

miniML: Constantes et Accès identificateur

► Constante : Valeur ne change pas

$$\frac{}{\gamma \vdash \mathit{entier} \Rightarrow \mathit{entier}} \\ \\ \\ \frac{}{\gamma \vdash \mathit{booleen} \Rightarrow \mathit{booleen}} \\$$

- ► Identificateur : Accès à l'environnement
 - Présent : Transmission valeur associée

$$\frac{x \in \gamma \quad \gamma(x) = \nu}{\gamma \vdash x \Rightarrow \nu}$$

► Absent : Cas d'erreur

$$\frac{x \notin \gamma}{\gamma \vdash x \Rightarrow \bot_{undef}}$$

miniML: Opérateur Unaire

- ► Étape préliminaire : Calcul du paramètre
- ► Variante 1 : Résultat correct du bon type

$$\frac{\gamma \vdash e \Rightarrow v \quad v \neq \bot \quad v \in \mathit{dom}\,\mathit{op} \quad v' = \mathit{op}\,v}{\gamma \vdash \mathit{op}\,e \Rightarrow v'}$$

Variante 2 : Résultat erroné

$$\frac{\gamma \vdash e \Rightarrow v \quad v = \bot_c}{\gamma \vdash op \ e \Rightarrow \bot_c}$$

► Variante 3 : Résultat correct du mauvais type

$$\frac{\gamma \vdash e \Rightarrow v \quad v \neq \bot \quad v \notin \mathit{dom}\,\mathit{op}}{\gamma \vdash \mathit{op}\,\,e \Rightarrow \bot_\mathit{type}}$$

miniML: Opérateur Binaire

- Étapes préliminaires : Calcul des paramètres
- Question : Y a t'il un ordre particulier?
- ▶ En absence d'effets de bord : Non, concurrence/parallélisme possible
- Variante 1 : Résultats corrects du bon type

Variante 2 : Résultat(s) erroné(s)

$$\frac{\gamma \vdash e_1 \Rightarrow v_1 \quad v_1 = \bot_c}{\gamma \vdash e_1 \ op \ e_2 \Rightarrow \bot_c} \quad \frac{\gamma \vdash e_2 \Rightarrow v_2 \quad v_2 = \bot_c}{\gamma \vdash e_1 \ op \ e_2 \Rightarrow \bot_c}$$

- Que se passe t'il si deux erreurs se produisent de natures différentes?
- Définir une règle qui explicite ce cas
- ► Variante 3 : Résultat correct du mauvais type

$$\frac{\gamma \vdash e_1 \Rightarrow v_1 \quad \gamma \vdash e_2 \Rightarrow v_2 \quad v_1 \neq \bot \quad v_2 \neq \bot \quad v_1 \times v_2 \notin \textit{dom op}}{\gamma \vdash e_1 \textit{ op } e_2 \Rightarrow \bot_{\textit{type}}}$$

miniML: Opérateur Binaire Droite à Gauche

- ► Imposons un ordre d'évaluation de droite à gauche (celui de OCaML)
- Variante 1 : Résultats corrects du bon type

Attention : Cette règle n'impose pas d'ordre

► Variante 2 : Résultat(s) erroné(s)

$$\frac{\gamma \vdash e_2 \Rightarrow v_2 \quad v_2 = \bot_c}{\gamma \vdash e_1 \text{ op } e_2 \Rightarrow \bot_c} \quad \frac{\gamma \vdash e_2 \Rightarrow v_2}{v_2 \neq \bot} \quad \gamma \vdash e_1 \Rightarrow v_1 \quad v_1 = \bot_c}{\gamma \vdash e_1 \text{ op } e_2 \Rightarrow \bot_c}$$

- 2 erreurs ne peuvent plus se produire en même temps
- ► Variante 3 : Résultat correct du mauvais type

$$\frac{\gamma \vdash e_1 \Rightarrow v_1 \quad \gamma \vdash e_2 \Rightarrow v_2 \quad v_1 \neq \bot \quad v_2 \neq \bot \quad v_1 \times v_2 \notin \mathit{dom\,op}}{\gamma \vdash e_1 \ \mathit{op} \ e_2 \Rightarrow \bot_\mathit{type}}$$

Exemple d'exécution d'un programme miniML

- ightharpoonup Prenons : $\gamma = \{v \mapsto 2\}$
- \triangleright Calculons le programme miniML : 1 + ν * 3
- L'arbre est trop volumineux, décomposons en :

$$A = \frac{v \in \gamma \quad \gamma(v) = 2}{\gamma \vdash v \Rightarrow 2}$$

$$B = \frac{A \quad \gamma \vdash 3 \Rightarrow 3}{2 \neq \bot} \quad 2 \times 3 \in dom* \quad 6 = 2 \times 3}{\gamma \vdash v \times 3 \Rightarrow 6}$$

$$\frac{\gamma \vdash 1 \Rightarrow 1}{1 \neq \bot} \quad B \quad 1 \times 6 \in dom + 7 = 1 + 6}{\gamma \vdash 1 + v \times 3 \Rightarrow 7}$$

Définitions récursives

- Syntaxe: let rec $f = e_1$ in e_2
- ► Rappel : Définition simple

$$\frac{\gamma \vdash e_1 \Rightarrow v_1 \quad \gamma :: \{x \mapsto v_1\} \vdash e_2 \Rightarrow v_2}{\gamma \vdash \text{let } x = e_1 \text{ in } e_2 \Rightarrow v_2}$$

ightharpoonup Rendons f visible dans e_1 :

$$\frac{\gamma :: \{f \mapsto v_1\} \vdash e_1 \Rightarrow v_1 \quad \gamma :: \{f \mapsto v_1\} \vdash e_2 \Rightarrow v_2}{\gamma \vdash \text{let rec } f = e_1 \text{ in } e_2 \Rightarrow v_2}$$

- Question : Est ce bien fondé?
- ► Remarque :

let rec $f = e_1$ in $e_2 \equiv \text{let } f = \text{let rec } f = e_1$ in e_1 in e_2

Exploitons cette relation :

$$\frac{\gamma \vdash \texttt{let rec } f = e_1 \texttt{ in } e_1 \Rightarrow v_1 \quad \gamma :: \{f \mapsto v_1\} \vdash e_2 \Rightarrow v_2}{\gamma \vdash \texttt{let rec } f = e_1 \texttt{ in } e_2 \Rightarrow v_2}$$

Est ce un progrès?

Définitions récursives

Si nous le faisons une seconde fois :

$$\frac{\gamma \vdash \mathtt{let} \ \mathtt{rec} \ f = e_1 \ \mathtt{in} \ e_1 \ \Rightarrow \ v_1 \quad \gamma :: \{f \mapsto v_1\} \vdash \ e_1 \ \Rightarrow \ v_1}{\gamma \vdash \mathtt{let} \ \mathtt{rec} \ f = e_1 \ \mathtt{in} \ e_1 \ \Rightarrow \ v_1}$$

- ► Si e_1 s'évalue en une fonction $\langle \text{fun } x \rightarrow e_3, \gamma_{def} \rangle$
- Nous pouvons alors poursuivre le calcul de e₂ en exploitant cette fermeture
- Nous en déduisons la règle simplifiée dans laquelle nous gelons le calcul de la définition récursive

$$\frac{\gamma :: \{f \mapsto \langle \text{let rec } f = e_1 \text{ in } e_1, \gamma \rangle\} \vdash e_2 \Rightarrow v}{\gamma \vdash \text{let rec } f = e_1 \text{ in } e_2 \Rightarrow v}$$

► Il faut alors ajouter une règle qui degèle le calcul lors de l'accès à f dans l'environnement :

$$\frac{x \in \gamma \quad \gamma(x) = \langle e, \gamma_{def} \rangle \quad \gamma_{def} \vdash e \Rightarrow v}{\gamma \vdash x \Rightarrow v}$$

$$\frac{x \in \gamma \quad \gamma(x) = v \quad v \neq \langle e, \gamma_{def} \rangle}{\gamma \vdash x \Rightarrow v}$$

Analyse de programmes

- Objectif : Déterminer les propriétés des programmes
- Analyse dynamique : Exécuter les programmes pour observer les propriétés
- Approche incomplète :
 - Exécution finie : Nombre d'étapes d'exécution fini
 - Nombre d'exécution fini
- Analyse statique : Déterminer les propriétés sans exécuter les programmes
 - Abstraction finie d'une exécution
 - Exécution symbolique du programme (interprétation abstraite)
 - Approche complète : Abstraction de toutes étapes de toutes les exécutions possibles
 - ► Approche correcte : Sur-approximation des propriétés réelles
- Exemple : Détecter certaines erreurs d'exécution sans exécuter les programmes (Définitions, Typage, Erreurs de calcul, Consommation ressources, . . .)

Mécanisme de typage

- Notion de type : Ensemble de valeurs pour lesquelles le programme a le même comportement
- Langage des types possibles : Syntaxe des types
 - Pour les expressions de miniML : bool et int
- Sémantique des types : Ensemble des valeurs possibles y compris les erreurs à l'exécution
 - ▶ $[bool] = \{true, false, \bot_{runtime}\}$
 - $\blacktriangleright \ \llbracket \texttt{int} \rrbracket = \mathbb{Z} \cup \{\bot_{\textit{runtime}}\}$
- ► Relations de comparaison des types :
 - Égalité
 - Compatibilité :
 - ► Généricité/Instanciation, Polymorphisme paramètrique
 - Sous-typage, Polymorphisme d'héritage
- Règles de calcul (en miniML, Unification des types)

Analyseur statique : Principes généraux

- Programme qui détermine les propriétés d'un programme
- Langage hôte/support : Langage de programmation de l'analyseur
- ► Représenter le programme comme une donnée
- ► Représenter les propriétés comme des données
- Exprimer les règles de vérification comme des algorithmes
 - Résultats de la vérification (dont intermédiaires)
 - Pour chaque construction exécutable du langage, identifier :
 - 1. Variantes selon résultats intermédiaires
 - 2. Étapes dans chaque variante
 - 3. Contraintes entre les étapes

Application à miniML

- ► Arbre abstrait : voir vidéo séparée
- Syntaxe des types :

$$Type \rightarrow bool$$
 | int

- ► Représentation des types et unification : voir vidéo séparée
- ► Algorithme de typage : voir vidéo séparée

Sémantique Axiomatique

- Objectif : Décrire formellement les mécanismes d'analyse des propriétés des programmes d'un langage
- Principe :
 - Exploiter la syntaxe du langage
 - Décrire les relations entre les constructions du langage et les propriétés
- Notation : Règles de déduction
- ▶ Jugement de typage : $\sigma \vdash e : \tau$
 - $ightharpoonup \sigma$: environnement (association *Ident / Type*)
 - e : expression (Expr)
 - ightharpoonup au : type (*Type*)
- Partie haute : Étapes intermédiaires (appels récursifs dans typeur miniML)
- ▶ Partie basse : Construction traitée par la règle
- Principe de construction : Règles d'exécution congrue par la sémantique des types (façon classes d'équivalence)

miniML : Constantes et Accès identificateur

► Règles d'évaluation :

$$\overline{\gamma \vdash \mathit{entier} \Rightarrow \mathit{entier}} \quad \overline{\gamma \vdash \mathit{booleen} \Rightarrow \mathit{booleen}}$$

► Règles de typage :

$$\overline{\sigma \vdash entier : int} \quad \overline{\sigma \vdash booleen : bool}$$

- ► Identificateur : Accès à l'environnement
 - Transmission valeur associée :

$$\frac{x \in \gamma \quad \gamma(x) = \nu}{\gamma \vdash x \Rightarrow \nu}$$

Règle de typage associée :

$$\frac{x \in \sigma \quad \sigma(x) = \tau}{\sigma \vdash x : \tau}$$

miniML: Opérateur Unaire

- ► Étape préliminaire : Traitement du paramètre
- ▶ Variante 1 : Résultat correct du bon type

$$\frac{\gamma \vdash e \Rightarrow v \quad v \neq \bot \quad v \in dom \, op \quad v' = op \, v}{\gamma \vdash op \, e \Rightarrow v'}$$

Variante 2 : Résultat erroné

$$\frac{\gamma \vdash e \Rightarrow v \quad v = \bot_c}{\gamma \vdash op \ e \Rightarrow \bot_c}$$

Règle de typage associée :

$$\frac{\sigma \vdash e : \tau \quad \tau = dom \, op \quad \tau' = codom \, op}{\sigma \vdash op \, e : \tau'}$$

miniML: Opérateur Binaire Droite à Gauche

- Étapes préliminaires : Traitement des paramètres
- ▶ Variante 1 : Résultats corrects du bon type

Variante 2 : Résultat(s) erroné(s)

$$\frac{\gamma \vdash e_2 \Rightarrow v_2 \quad v_2 = \bot_c}{\gamma \vdash e_1 \text{ op } e_2 \Rightarrow \bot_c} \quad \frac{\gamma \vdash e_2 \Rightarrow v_2}{v_2 \neq \bot} \quad \gamma \vdash e_1 \Rightarrow v_1 \quad v_1 = \bot_c}{\gamma \vdash e_1 \text{ op } e_2 \Rightarrow \bot_c}$$

Règle de typage associée :

$$\frac{\sigma \vdash e_1 : \tau_1 \quad \sigma \vdash e_2 : \tau_2 \quad \tau_1 \times \tau_2 = \mathit{dom}\,\mathit{op} \quad \tau = \mathit{codom}\,\mathit{op}}{\sigma \vdash e_1 \,\mathit{op}\,e_2 : \tau}$$

Exemple de typage d'un programme miniML

- ightharpoonup Prenons : $\sigma = \{v : int\}$
- ▶ Typons le programme miniML : 1 + v * 3
- L'arbre est trop volumineux, décomposons en :

$$A = \frac{v \in \sigma \quad \sigma(v) = \text{int}}{\sigma \vdash v : \text{int}}$$

$$B = \frac{A \quad \text{int} \times \text{int} = dom*}{\sigma \vdash 3 : \text{int} \quad \text{int} = codom*}$$

$$\frac{\sigma \vdash 1 : \text{int} \quad \text{int} \times \text{int} = dom + dom*}{B \quad \text{int} = codom + dom*}$$

$$\frac{B \quad \text{int} = codom + dom*}{\sigma \vdash 1 + v * 3 : \text{int}}$$







Grammaires Attribuées : Principes généraux

- Objectif : Enricher la spécification de la syntaxe avec des éléments de sémantique
- Support : Règles de production
- Attributs sémantiques : Informations typées associées aux symboles (terminaux, non-terminaux)
- ► Équations sémantique : Relations entre les attributs des symboles q'une règle de production
- Question : Pour un programme donné, est il possible de calculer les valeurs des attributs sémantiques?
- ► Solution : Calcul d'un point fixe sur les équations sémantiques
- Problème : Existence du point fixe en temps fini ? Raisonnable ?
- Approche : Restriction sur la forme des équations pour assurer la terminaison

Grammaire L-attribuées

- Objectif : Calcul pendant l'analyse syntaxique
- Contrainte : Analyseur Descendant
- Attributs synthétisés : Attributs d'un non terminal dont la valeur est calculée pendant l'analyse de ce non terminal
- Attributs hérités : Attributs d'un non terminal dont la valeur est calculée avant l'analyse de ce non terminal
- Forme des équations : Exploitation de fonctions qui calculent la valeur des attributs
 - Synthétisés du symbole non terminal décrit par la règle
 - Hérités des symboles non terminaux exploités par la règle
- Contraintes :
 - Calcul de gauche à droite :
 - Calcul de haut en bas
 - Calcul de bas en haut



Exemple : Typage de miniML



Exemple : Exécution de miniM







